


# THÉORIE DES LANGAGES ET DES AUTOMATES

## CH3: LES GRAMMAIRES

Olfa MOUELHI  
***olfa.mouelhi@esprit.tn***



# PLAN

- Les grammaires
- Langage engendré par une grammaire
- Types de grammaires
- grammaires et dérivation
- Transformation d'une grammaire régulière en un automate fini
- Transformation d'automate fini en une grammaire régulière

# LES GRAMMAIRES

Une grammaire  $G$  est un système de réécriture dans un alphabet  $V_n \cup V_t$  formé de deux alphabets disjoints ( $V_n \cap V_t = \emptyset$ ):

- $V_t$  l'alphabet terminal, celui des mots engendrés
- $V_n$  l'alphabet non terminal, ou alphabet des variables, contenant un élément particulier : l'*axiome*, et dont la partie gauche de chaque règle contient au moins une variable.
- $V = V_n \cup V_t$  est appelé le vocabulaire de la grammaire  $G$ .

# LES GRAMMAIRES

Exemple :

- $V_t = \{\text{chat, chien, le, mord, voit}\}$
- $V_n = \{\text{phrase, verbe, groupe\_nominal, article, nom}\}$

R:  
B:

*phrase* → *groupe\_nominal verbe groupe\_nominal*

*groupe\_nominal* → *article nom*

*article* → *le*

*nom* → *chat*

*nom* → *chien*

*verbe* → *mord*

*verbe* → *voit*

# LES GRAMMAIRES

On va pouvoir engendrer ("dériver") huit phrases différentes :

- $phrase \xRightarrow{*} le\ chat\ voit\ le\ chien$
- $phrase \xRightarrow{*} le\ chat\ voit\ le\ chat$
- $phrase \xRightarrow{*} le\ chien\ mord\ le\ chat$
- *etc.*

On a donc besoin de quatre choses différentes pour définir une grammaire :

- $V_t$  : est un ensemble fini de symboles dits terminaux, appelé vocabulaire terminal.
- $V_n$  : est un ensemble fini (disjoint de  $V_t$ ) de symboles dits non-terminaux, appelé vocabulaire non terminal.
- $L'axiome$  : est un non-terminal particulier appelé aussi source.
- $Les\ règles : R \subseteq (V^* \setminus V_t^*) \times V^*$  est un ensemble fini de règles de grammaire notées  $g \rightarrow d$  si  $(g, d) \in R$ .

# LES GRAMMAIRES

Une grammaire est une machine à réécrire c'est-à-dire, une machine à faire des substitutions.

Une règle de production  $(l, r) \in P$  est notée  $l \rightarrow r$  :  $l$  est la partie gauche, contenant au moins une variable,  $r$  est la partie droite.

Pour les grammaires, on dit dérivation plutôt que réécriture, et on note  $+$  au lieu de  $\cup$  pour décrire l'union de deux langages :  $X + V = X \cup V$  est l'alphabet de la grammaire.

# LES GRAMMAIRES

## LANGAGE ENGENDRÉ PAR UNE GRAMMAIRE

Une grammaire est un mécanisme permettant d'engendrer les phrases du langage, en récrivant un mot  $u \in V$  en un nouveau mot  $v \in V$ .

L'opération de réécriture consiste à remplacer une occurrence (quelconque) d'un non-terminal  $N$  (quelconque) de  $V_n$  présent dans  $u$  par un membre droit de règle dont  $N$  est membre gauche.

Ce processus est itéré à partir de la source jusqu'à l'élimination complète des non-terminaux.

# LES GRAMMAIRES

## DÉFINITION

Étant donnée une grammaire  $G = \{V_t, V_n, S, R\}$ , on dit que le mot  $u \in V^*$  se réécrit en le mot  $v \in V^*$  dans  $G$  avec la règle  $g \rightarrow d$ , et l'on note :

$$u \xrightarrow{g \rightarrow d} v$$

Si :

- 1)  $u = w_1 g w_2$ , où  $w_1 \in V^*$  et  $w_2 \in V^*$ .
- 2)  $v = w_1 d w_2$

On dit que le mot  $u \in V^*$  se réécrit en le mot  $v \in V^*$  dans la grammaire  $G$  s'il existe une règle  $g \rightarrow d \in R$  telle que  $u$  se réécrit en  $v$  dans  $G$ .

Enfin, on dit que le mot  $v \in V^*$  dérive du mot  $u \in V^*$ , dans la grammaire  $G$ , ce que l'on note par  $u \xrightarrow{*} v$ , s'il existe une suite finie  $w_0, w_1, \dots, w_n$  de mots de  $V^*$  telle que  $w_0 = u$ ,  $w_i \rightarrow w_{i+1}$  pour tout  $i \in [0, n - 1]$ , et  $w_n = v$ .

# LES GRAMMAIRES

## EXEMPLE

$G_1$

$$\begin{aligned} N &\rightarrow 0 \\ N &\rightarrow 1 \\ N &\rightarrow 1M \\ M &\rightarrow 0 \\ M &\rightarrow 1 \\ M &\rightarrow 0M \\ M &\rightarrow 1M \end{aligned}$$
$$\begin{aligned} N &\rightarrow 0 \\ N &\rightarrow 1M \\ M &\rightarrow \varepsilon \\ M &\rightarrow 0M \\ M &\rightarrow 1M \end{aligned}$$

$G_2$

**Les deux grammaires décrivent les entiers écrits en binaire**

# LES GRAMMAIRES

**EXEMPLE**  
**11010**

En utilisant la première grammaire :

$N \rightarrow 1M \rightarrow 11M \rightarrow 110M \rightarrow 1101M \rightarrow 11010$

En utilisant la deuxième grammaire :

$N \rightarrow 1M \rightarrow 11M \rightarrow 110M \rightarrow 1101M \rightarrow 11010M \rightarrow 11010$

Le mot  $11010M$  dérive du mot  $1M$

$1\underline{M} \rightarrow 11\underline{M} \rightarrow 110\underline{M} \rightarrow 1101\underline{M} \rightarrow 11010M$

$G_1$

|     |               |      |
|-----|---------------|------|
| $N$ | $\rightarrow$ | $0$  |
| $N$ | $\rightarrow$ | $1$  |
| $N$ | $\rightarrow$ | $1M$ |
| $M$ | $\rightarrow$ | $0$  |
| $M$ | $\rightarrow$ | $1$  |
| $M$ | $\rightarrow$ | $0M$ |
| $M$ | $\rightarrow$ | $1M$ |

$G_2$

|     |               |               |
|-----|---------------|---------------|
| $N$ | $\rightarrow$ | $0$           |
| $N$ | $\rightarrow$ | $1M$          |
| $M$ | $\rightarrow$ | $\varepsilon$ |
| $M$ | $\rightarrow$ | $0M$          |
| $M$ | $\rightarrow$ | $1M$          |

# LES GRAMMAIRES

## DÉFINITION

Le langage engendré par la grammaire  $G$  est l'ensemble des mots de  $V_t$  qui dérivent de l'axiome de  $G$ , que l'on note par  $\mathcal{L}(G)$ .

## REMARQUE

Les grammaires de l'exemple précédent peuvent aussi être spécifiées de la manière suivante :

$G_1$

$$\begin{aligned} N &\rightarrow 0 \mid 1 \mid 1M \\ M &\rightarrow 0 \mid 1 \mid 0M \mid 1M \end{aligned}$$

$$\begin{aligned} N &\rightarrow 0 \mid 1M \\ M &\rightarrow \varepsilon \mid 0M \mid 1M \end{aligned}$$

$G_2$

# GRAMMAIRES CONTEXTUELLES

La grammaire suivante décrit le langage  $\{a^n b^n c^n \mid n \geq 0\}$ . Ses règles ont la particularité d'avoir un membre droit de taille supérieure ou égale à celle de leur membre gauche.

$$S \rightarrow aSBC \mid \varepsilon$$

$$CB \rightarrow BC$$

$$aB \rightarrow ab$$

$$bB \rightarrow bb$$

$$bC \rightarrow bc$$

$$cC \rightarrow cc$$

# GRAMMAIRES CONTEXTUELLES

$a^3b^3c^3$

$S \rightarrow aSBC$

$\rightarrow a(aSBC)BC$

$\rightarrow a(a(aSBC)BC)BC$

$\rightarrow aaaB CBCBC$

$\rightarrow aaaB BC CBC$

$\rightarrow aaaB BC BC C$

$\rightarrow aa aBBBCC C$

$\rightarrow aa abBBCC C$

$\rightarrow aa abbBCC C$

$\rightarrow aa abbbCC C$

$\rightarrow aa abbb cCC$

$S \rightarrow \varepsilon$

$CB \rightarrow BC$

$CB \rightarrow BC$

$CB \rightarrow BC$

$aB \rightarrow ab$

$bB \rightarrow bb$

$bB \rightarrow bb$

$bC \rightarrow bc$

$cC \rightarrow cc$

$\rightarrow aaabbbccC$

$\rightarrow aaabbbccc$

$cC \rightarrow cc$

$a^3b^3c^3$

# GRAMMAIRES CONTEXTUELLES

## DÉFINITION

Étant donnée une grammaire  $G = \{V_t, V_n, S, R\}$ , une règle de  $R$  est dite contextuelle si elle est de la forme  $g \rightarrow d$  avec  $|g| \leq |d|$ . Une grammaire est contextuelle si toutes ses règles le sont, et le langage engendré est alors dit contextuel.

Les langages de ce type sont reconnus par des machines de Turing particulières utilisant un espace mémoire borné.

# GRAMMAIRES HORS-CONTEXTE

La grammaire suivante décrit le langage  $\{a^n b^n \mid n \geq 0\}$ . Cette grammaire a une particularité : le membre gauche de chaque règle est un non-terminal..

$$S \rightarrow aSb \mid \varepsilon$$

# GRAMMAIRES HORS-CONTEXTE OU ALGÈBRIQUES

## DÉFINITION

Étant donnée une grammaire  $G = \{V_t, V_n, S, R\}$ , une règle de  $R$  est dite hors-contexte si elle est de la forme  $N \rightarrow u$  où  $u \in V^*$ . Une grammaire est hors-contexte si toutes ses règles le sont, et le langage engendré est alors dit hors-contexte. On note par  $LHC$  la classe des langage hors-contexte.

Les langages hors-contexte sont reconnus par les automates à pile, que nous découvrirons plus loin dans ce cours.

# GRAMMAIRES RÉGULIÈRES

Les grammaires de l'exemple suivant sont hors-contexte, mais elles ont une particularité supplémentaire : le membre droit possède au plus une occurrence de symbole non terminal, située à l'extrémité droite.

$G_1$

$$N \rightarrow 0 \mid 1 \mid 1M$$

$$M \rightarrow 0 \mid 1 \mid 0M \mid 1M$$

$$N \rightarrow 0 \mid 1M$$

$$M \rightarrow \varepsilon \mid 0M \mid 1M$$

$G_2$

# GRAMMAIRES RÉGULIÈRES

## DÉFINITION

Étant donnée une grammaire  $G = \{V_t, V_n, S, R\}$ , une règle de  $R$  est dite régulière si elle est de la forme  $N \rightarrow u$  ou  $N \rightarrow uM$ , où  $M, N \in V_n$  et  $u \in V_t^*$ . Une grammaire est régulière si toutes ses règles le sont, et un langage engendré par une telle grammaire est alors dit régulier ou de type 3.

Les langages réguliers sont bien sûr reconnus par un automate fini.

Un langage est dit régulier si et seulement si il est reconnaissable.

# GRAMMAIRES ET DÉRIVATION

- Une dérivation est l'application répétée de règles qui commence avec le symbole de départ et se termine avec une séquence de terminaux.
- Une phrase est une forme sententielle ne contenant que des terminaux.
- Les dérivations dans  $G = (V, S, R)$  sont des suites de réécritures que l'on peut opérer sur les éléments de  $(\Sigma + V)^*$  par application de ses règles.
- Une dérivation élémentaire est l'application d'une règle de la grammaire.
- Une dérivation élémentaire se définit pour  $\beta_1 \in (\Sigma + V)^*$ ,  $\beta_2 \in (\Sigma + V)^*$ ,  $X \in V$  par:  
$$\beta_1 X \beta_2 \Rightarrow \beta_1 \alpha \beta_2$$
  
pour toute règle  $X \rightarrow \alpha$  de la grammaire.

# GRAMMAIRES ET DÉRIVATION

- Une dérivation de longueur  $i$  notée :  $\beta \xRightarrow{i} \gamma$  est une suite de  $i$  dérivations élémentaires qui s'enchaînent, qui se définit par récurrence sur  $i$  :  
 $0$  :  $\beta \Rightarrow \beta$  Pas d'application de règle.  
 $i \rightarrow i + 1$  :  $\beta \xRightarrow{i} \delta \xRightarrow{1} \gamma$  Une application de plus
- On notera  $\beta \xRightarrow{*} \gamma$  pour signifier qu'il existe une dérivation  $\beta \xRightarrow{i} \gamma$ .

# GRAMMAIRES ET DÉRIVATION

Considérons le langage des expressions arithmétiques. Cette grammaire aura alors pour symboles terminaux  $V_t = \{+, \times, (, ), Id, Cte\}$  et pour non-terminaux l'unique symbole  $E$  qui sera donc la source :

$$E \rightarrow Id \mid Cte \mid E + E \mid E \times E \mid (E)$$

Cette grammaire permet d'engendrer l'expression arithmétique  $x + 2.5 \times 4 + (y + z)$ , en supposant que les mots  $2.5$  et  $4$  font partie du langage engendré par la grammaire des constantes, et que  $x, y, z$  font partie du langage engendré par la grammaire des variables.

# GRAMMAIRES ET DÉRIVATION

$$E \rightarrow Id \mid Cte \mid E + E \mid E \times E \mid (E)$$

$$x + 2.5 \times 4 + (y + z)$$

$$E \rightarrow E + E$$

$$E \rightarrow Id + E$$

$$E \rightarrow Id + E \times E$$

$$E \rightarrow Id + Cte * E$$

$$E \rightarrow Id + Cte \times E + E$$

$$E \rightarrow Id + Cte \times Cte + E$$

$$E \rightarrow Id + Cte \times Cte + (E)$$

$$E \rightarrow Id + Cte \times Cte + (E + E)$$

$$E \rightarrow Id + Cte \times Cte + (Id + E)$$

$$E \rightarrow Id + Cte \times Cte + (Id + Id)$$

$$\begin{array}{ccccc} \downarrow & \downarrow & \downarrow & \downarrow & \downarrow \\ x & 2.5 & 4 & y & z \end{array}$$

Chaque fois on prend le terminal le plus à gauche  $\Rightarrow$  dérivation à gauche.

# GRAMMAIRES ET DÉRIVATION

$$E \rightarrow Id \mid Cte \mid E + E \mid E \times E \mid (E)$$

$$x + 2.5 \times 4 + (y + z)$$

$$E \rightarrow E + E$$

$$E \rightarrow E + (E)$$

$$E \rightarrow E + (E + E)$$

$$E \rightarrow E + (E + Id)$$

$$E \rightarrow E + (Id + Id)$$

$$E \rightarrow E \times E + (Id + Id)$$

$$E \rightarrow E \times Cte + (Id + Id)$$

$$E \rightarrow E + E \times Cte + (Id + Id)$$

$$E \rightarrow E + Cte \times Cte + (Id + Id)$$

$$E \rightarrow Id + Cte \times Cte + (Id + Id)$$

$$\begin{array}{ccccc} \downarrow & \downarrow & \downarrow & \downarrow & \downarrow \\ x & 2.5 & 4 & y & z \end{array}$$

Chaque fois on prend le terminal le plus à droite  $\Rightarrow$  dérivation à droite.

# GRAMMAIRES ET DÉRIVATION

- Étant donné la grammaire des expressions arithmétiques :  
 $E \rightarrow Id \mid Cte \mid E + E \mid E \times E \mid (E)$
- Considérons la phrase  $Id + Id \times Id$ .
- La dérivation à droite de cette phrase est :

$$\begin{aligned} E &\rightarrow \mathbf{E} + \mathbf{E} \\ &\rightarrow \mathbf{E} + Id \\ &\rightarrow \mathbf{E} \times \mathbf{E} + Id \\ &\rightarrow \mathbf{E} + Id \times \mathbf{id} \\ &\rightarrow Id + Id \times Id \end{aligned}$$

$$\begin{aligned} E &\rightarrow \mathbf{E} \times E \\ &\rightarrow \mathbf{E} + E \times E \\ &\rightarrow Id + \mathbf{E} \times E \\ &\rightarrow Id + Id \times \mathbf{E} \\ &\rightarrow Id + Id \times Id \end{aligned}$$

## DÉFINITION

Une grammaire  $G$  est **ambiguë** s'il existe un mot  $w \in \mathcal{L}(G)$  qui possède plusieurs dérivations gauches (droites) dans  $G$ .

### Exemple:

$$E \rightarrow E+E \mid E^*E \mid (E) \mid x_1 \mid x_2$$

Soit  $w = x_1+x_1*x_2$

Cette grammaire est ambiguë car la chaîne  $w$  a plus d'une dérivation gauche:

$$E \rightarrow \underline{E}+E \rightarrow x_1+\underline{E} \rightarrow x_1+\underline{E}^*E \rightarrow x_1+x_1^*\underline{E} \rightarrow x_1+x_1^*x_2$$

$$E \rightarrow \underline{E}^*E \rightarrow \underline{E}+E^*E \rightarrow x_1+\underline{E}^*E \rightarrow x_1+x_1^*\underline{E} \rightarrow x_1+x_1^*x_2$$

De même on peut trouver deux dérivations droites

# REPRÉSENTATION ARBORESCENTE

Une dérivation est l'enchaînement séquentiel de dérivations élémentaires, mais ceci est généralement obtenu au prix de choix qui, en réalité, sont arbitraires.

Soient  $Y \rightarrow \beta$  et  $Y' \rightarrow \beta'$  deux règles de  $G$ . Elles sont applicables à tout mot de la forme  $\alpha_1 Y \alpha_2 Y \alpha_3$  pour produire les deux dérivations :

$$D_1 : \alpha_1 Y \alpha_2 Y' \alpha_3 \Rightarrow \alpha_1 \beta \alpha_2 Y' \alpha_3 \Rightarrow \alpha_1 \beta \alpha_2 \beta' \alpha_3$$

$$D_2 : \alpha_1 Y \alpha_2 Y' \alpha_3 \Rightarrow \alpha_1 Y \alpha_2 \beta' \alpha_3 \Rightarrow \alpha_1 \beta \alpha_2 \beta' \alpha_3$$

La commutation de règles dans une dérivation est le remplacement de  $D_1$  par  $D_2$  ou celui de  $D_2$  par  $D_1$  : une telle opération ne modifie pas la nature d'une dérivation mais seulement la façon de la décrire.

# REPRÉSENTATION ARBORESCENTE



## DÉFINITION

Deux dérivations sont dites équivalentes si et seulement si on peut transformer l'une en l'autre par une suite de commutations de règles.

# REPRÉSENTATION ARBORESCENTE

## ARBRE DE DÉRIVATION D'UNE GRAMMAIRE


L'idée est simplement d'arborer chaque règle  $X \rightarrow \varepsilon$ ,  $X \rightarrow \xi_1 \dots \xi_m$  de  $\mathcal{G}$ , en la représentant sous la forme d'un embranchement ordonné, sur le modèle ci-dessous :




# REPRÉSENTATION ARBORESCENTE

## EXAMPLE : ID + ID × ID

$E \Rightarrow E + E$   
 $\Rightarrow id + E$   
 $\Rightarrow id + E \times E$   
 $\Rightarrow id + id \times E$   
 $\Rightarrow id + id \times id$



$E \Rightarrow E \times E$   
 $\Rightarrow E + E \times E$   
 $\Rightarrow id + E \times E$   
 $\Rightarrow id + id \times E$   
 $\Rightarrow id + id \times id$




# TRANSFORMATION D'UNE GRAMMAIRE RÉGULIÈRE EN UN AUTOMATE FINI :

Soit  $G=(V,T,S,R)$  une grammaire régulières, on peut construire un automate fini  $A=(Q,\Sigma,\delta,q_0,F)$  qui accepte les mots engendrés par  $G$ :

- Pour toutes les productions  $B \rightarrow \alpha$  de  $P$ , on ajoute un nouveau symbole non terminal  $X$  et on remplace ces productions par  $B \rightarrow \alpha X$  et  $X \rightarrow \epsilon$
- L'ensemble des états  $Q$  de l'automate est celui des non-terminaux.  $Q=V$
- L'alphabet  $\Sigma$  est égal à l'ensemble  $T$  des terminaux.  $\Sigma=T$
- L'état  $q_0$  correspond à l'axiome  $A$  de la grammaire.  $q_0=S$
- $\delta = \{(p,x,q) / \text{il existe une règle de la forme } p \rightarrow xq\}$
- $F = \{X / X \rightarrow \epsilon\}$

## Exemple

- $G=(V,T,A,R)$  une grammaire régulière
- $V=\{A,B\}$  axiome  $A$
- $T=\{a,b,c\}$
- $R=\{A \rightarrow aA$   
     $A \rightarrow bB$   
     $A \rightarrow c$  (devient  $A \rightarrow cX$  et  $X \rightarrow \epsilon$ )  
     $B \rightarrow bB$   
     $B \rightarrow a$  (devient  $B \rightarrow aX$ )  
     $B \rightarrow \epsilon$



# TRANSFORMATION D'UN AUTOMATE FINI EN UNE GRAMMAIRE RÉGULIÈRE:

Soit un automate fini donné  $M=(Q,\Sigma,\delta, q_0,F)$

La grammaire  $G=(V,T,S,R)$  équivalente est définie comme suit :

- $V=Q$
- $T= \Sigma$
- $S= q_0$
- $R=\{p \rightarrow xq / (p,x,q) \in \delta \} \cup \{Q \rightarrow \varepsilon / Q \in F\}$

## Exemple :

- $A = (Q, \Sigma, \delta, q_0 = A, F)$

$\Sigma = \{a, b\}, Q = \{A, B, C, D\}, F = \{D\}$

- $G = (V, T, A, R)$

$V = \{A, B, C, D\}, T = \{a, b\}$ , axiome A

$R = \{A \rightarrow aC, A \rightarrow bB, B \rightarrow aD, B \rightarrow bA, C \rightarrow aD, C \rightarrow bB, D \rightarrow aD, D \rightarrow bD, D \rightarrow \varepsilon\}$

